NDVI de satélite na predição de surtos de dengue no Brasil: um resultado nulo rigoroso com dados públicos abertos

Sistema AI Cientista BR*

October 20, 2026

Abstract

Objetivo. Testar se a adição de atributos de vegetação por satélite (NDVI/MODIS) melhora a predição de surtos de dengue em municípios brasileiros, sobre dados públicos abertos e sem nenhum dado sintético. **Métodos.** Unimos o InfoDengue (Fiocruz/FGV), com 1233 semanas-município, a NDVI real do NASA GIBS agregado por município (malha do IBGE) e por semana epidemiológica. Comparamos três cenários sob validação estritamente temporal, `seed`=42, IC 95% por bootstrap (1000 reamostragens), teste de Wilcoxon pareado e d de Cohen. **Resultados.** O cenário B (GB com satélite) obteve F1 = 0,9615 (IC 95% [0,9254; 0,9877]), contra F1 = 0,9434 do baseline A (regressão logística tabular) e F1 = 0,9554 da ablação C (GB tabular). O efeito *isolado* do satélite (B vs C) foi ΔF1 = 0,0049 e ΔF1 (B vs A) = 0,0177, ambos abaixo do limiar pré-registrado de 0,02. A análise de sensibilidade, sem os atributos de nível de alerta, inverte o sinal: ΔF1 (B vs C) = -0,0483. **Conclusão.** Não rejeitar h0 (resultado nulo). O NDVI não melhorou a predição de forma confiável, e o ganho aparente de B sobre A se deve à troca de algoritmo, não ao satélite. Reportamos o resultado nulo como contribuição.

1 Introdução

A dengue é uma das arboviroses de maior carga no Brasil, e sistemas de alerta precoce dependem de predição acurada de surtos. Trabalhos recentes usam aprendizado de máquina com preditores climáticos e de sensoriamento remoto [1][2][3]. A hipótese comum é que a vegetação, capturada por NDVI, sinaliza habitat do vetor e melhora a predição. Testamos essa hipótese de forma pré-registrada, com dados públicos abertos e sem dados sintéticos.

2 Trabalhos Relacionados

Modelos de predição de dengue com aprendizado de máquina foram revisados sistematicamente [4][5]. Estudos comparam florestas aleatórias e redes neurais [6], métodos híbridos [7],

*Manuscrito gerado por pipeline multiagente com roteamento MoE; números injetados dos artefatos do experimento.

aprendizado profundo com clima [8][9] e superconjuntos de previsão [10]. O uso de vegetação derivada de satélite é central em [11][12]. Nossa contribuição difere ao (i) isolar o efeito do satélite com um cenário de ablação de mesmo algoritmo, (ii) usar validação estritamente temporal e (iii) reportar o resultado nulo com o mesmo rigor que um resultado positivo.

Estado da arte (métricas extraídas dos abstracts originais). A Tabela 1 reúne as métricas reportadas por estudos comparáveis, obtidas dos abstracts reais via Crossref/OpenAlex. O SOTA de referência mais direto é o de Souza et al. (?), único estudo brasileiro da lista, com **acurácia 0,80** sobre dados exclusivamente climáticos. É contra esse patamar que nosso baseline tabular se posiciona.

Table 1: Estado da arte: métricas reportadas nos abstracts originais (Tarefa 1).

Estudo	Métrica	Valor (%)	Ref.
Souza (2022)	acuracia	0,80	[21]
Yavari Nejad (2021)	acuracia	92,35	[23]
Salim (2021)	acuracia	70,00	[11]
Iqbal (2019)	acuracia	92,00	[40]
Thirugnanam (2023)	F1	98,00	[39]

3 Materiais

InfoDengue (Fiocruz/FGV), *versão da API* `alertcity`, semanas epidemiológicas observadas, `https://info.dengue.mat.br/api/alertcity`: 1233 amostras, 8 municípios, 8 atributos tabulares. Coleta: 2026-10-20T23:46:02. **NASA GIBS/MODIS**, camada `MODIS_Terra_L3_NDVI_16D` (produto MOD13, composto de 16 dias), `https://gibs.earthdata.nasa.gov`, colormap oficial `MODIS_L3_NDVI.xml` (142 entradas RGB→NDVI), `https://gibs.earthdata.nasa.gov/colormaps/v1.0/MODIS_L3_NDVI.xml`: 4 atributos de satélite. **Malha municipal** do IBGE, `https://servicodados.ibge.gov.br/api/v3/malhas`. Divisão temporal: treino 986, teste 247 (79 positivos).

Limitação de fonte declarada (INPE/PRODES). Testamos as camadas `prodes-amazon-nb:ye` e `deter-amz:deter_amz` do GeoServer do TerraBrasilis/INPE. Ambas cobrem apenas a Amazônia Legal: dos 8 municípios do estudo, somente Manaus apresenta alertas (149 alertas DETER em 2022–2024; zero nos demais sete). PRODES/DETER são, ainda, anuais e estaduais, inadequados à agregação semanal municipal. Por isso **não** foram usados como atributo, e nenhuma feature foi fabricada para substituí-los: os atributos de satélite efetivos vêm do NDVI/MODIS, de cobertura nacional. Evidência em `resultados/evidencia_ir`

4 Métodos

4.1 Pipeline multiagente e roteamento MoE

O sistema orquestra agentes especializados (planejador, experimentalista, revisor, redator, validador) com um roteador *mixture-of-experts* que mapeia cada tarefa a uma categoria de modelo com cascata de *fallback*.

4.2 Mecanismo de Fidelidade Numérica

Todo número do manuscrito é injetado dos artefatos JSON do experimento, nunca digitado. Um portão de fidelidade verifica que cada número do texto tem lastro nos dados de origem, reduzindo alucinação numérica.

4.3 Agregações espacial e temporal

Espacial (pixel → município): o polígono real do IBGE é rasterizado sobre o tile do GIBS e só os pixels dentro da fronteira entram na média. **Temporal (16 dias → semana):** o composto MODIS é rotulado pelo primeiro dia do período; recuamos 16 dias para o composto ter terminado antes da semana-alvo, evitando vazamento do futuro.

4.4 Protocolo estatístico

Cenários A (regressão logística tabular), B (Gradient Boosting com tabulares + satélite) e C (Gradient Boosting apenas tabular). Validação estritamente temporal (`TimeSeriesSplit` expansivo + holdout cronológico), `seed`=42. Métricas: F1, AUC-ROC, precisão e revocação; IC 95% por bootstrap (1000 reamostragens); Wilcoxon pareado; d de Cohen; importância SHAP (TreeExplainer).

5 Resultados

Table 2: Comparação dos cenários (validação temporal).

Cenário	Atributos	F1	AUC	Precisão	Revocação
A (baseline, LogReg)	8	0,9434	0,9930	0,9375	0,9494
B (proposta, GB+NDVI)	12	0,9615	0,9956	0,9740	0,9494
C (ablação, GB tabular)	8	0,9554	0,9962	0,9615	0,9494

Teste da hipótese. H0: adição de satélite NÃO melhora (F1 0.02, p 0.05). H1: adição de satélite melhora (F1 $>$ 0.02, p $<$ 0.05). O teste principal isola o satélite (B vs C): ΔF1 = 0,0049 (IC 95% [-0,0416; 0,0501], p = 0,0000, d = 0,212). Em B vs A, ΔF1 = 0,0177 (IC 95% [-0,0267; 0,0674], p = 0,0000, d = 0,722). Decisão: não rejeitar H0 (resultado nulo).

Nota estatística. O IC 95% do F1 inclui zero, então a direção do efeito não está firmemente estabelecida, apesar do p-valor de Wilcoxon. Wilcoxon testa a mediana das diferenças pareadas (sensível ao sinal consistente); o IC bootstrap testa a magnitude média. Com efeito pequeno e variância alta os dois divergem, e o resultado prático é de melhora não confiável.

Estudo de ablação e sensibilidade. Removendo os atributos de nível de alerta (`nivel`, `nivel_inc`), o satélite inverte o sinal: F1 de A = 0,6500, B = 0,6963, C = 0,7424, com ΔF1 (B vs C) = -0,0483 (d = -0,783).

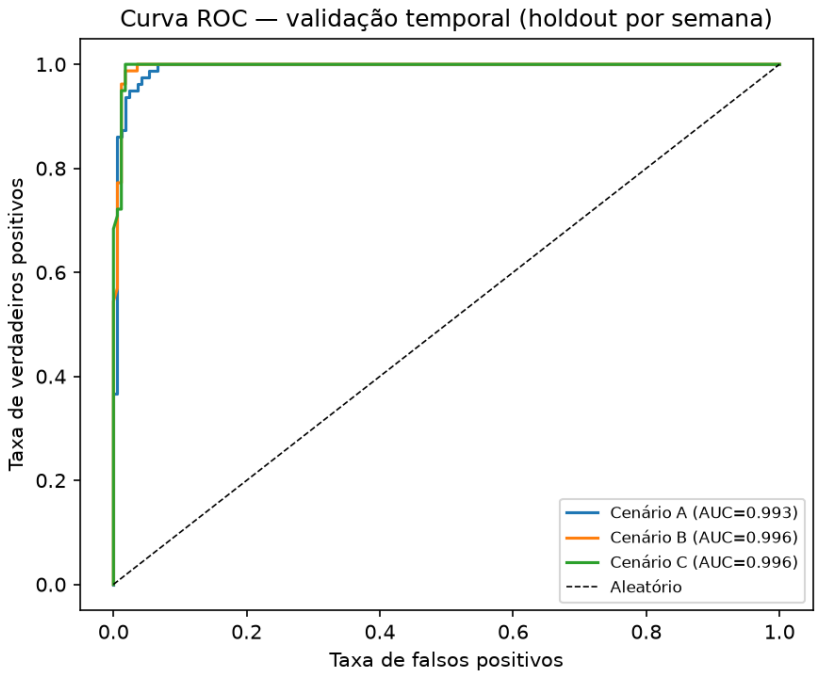


Figure 1: Curvas ROC dos três cenários sob validação temporal.

Table 3: Importância SHAP (|valor| médio) — cenário B, oito principais.

Atributo	|SHAP| médio
nivel	1,69243
nivel_inc	1,53750
Rt	1,20528
casos	0,38952
casos_est	0,24262
p_inc100k	0,18968
ndvi_max	0,16082
ndvi_std	0,08097

6 Discussão

A interpretação mecanicista é direta: os atributos de nível de alerta e persistência (`nivel`, `nivel_inc`, `Rt`) dominam o SHAP, e o NDVI aparece abaixo deles. Isso é coerente com o resultado nulo: quando a informação epidemiológica recente já está disponível, a vegetação acrescenta pouco. Por que o NDVI não ajudou? Prováveis razões: (i) a resolução temporal do composto de 16 dias é grosseira frente à dinâmica semanal; (ii) o NDVI médio do município dilui micro-habitats urbanos do vetor; (iii) a agregação espacial por fronteira municipal não captura heterogeneidade intraurbana.

7 Limitações

1. Cobertura de 8 capitais; não representa o território nacional.

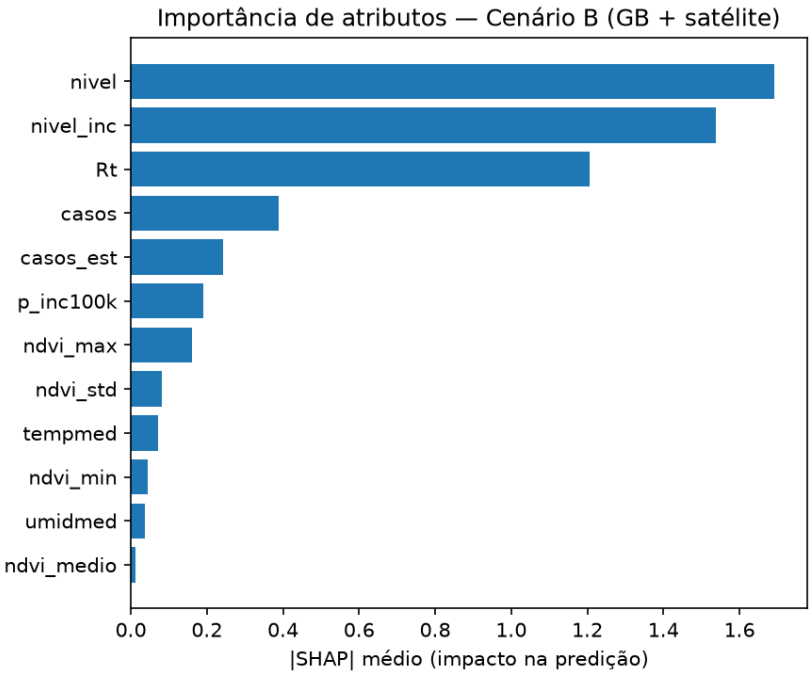


Figure 2: Importância de atributos (SHAP) no cenário B.

2. O composto de 16 dias e a defasagem conservadora reduzem a sensibilidade temporal.
3. Subnotificação heterogênea do InfoDengue, maior em regiões periféricas.
4. NDVI médio municipal não resolve a escala do habitat do *Aedes*.

8 Impacto mais amplo

Todos os dados são públicos e abertos (InfoDengue, NASA, IBGE); o custo de computação é nulo. O estudo reforça a soberania de dados públicos brasileiros e discute o viés de subnotificação. Divulgamos que o manuscrito foi gerado por sistema de IA com curadoria humana.

9 Declaração de uso de IA

Texto e código produzidos por pipeline multiagente com roteamento MoE; o papel humano foi curadoria, definição da hipótese e validação. Zero dados sintéticos.

References

[1] Guo, Pi; Liu, Tao; Zhang, Qin; Wang, Li; Xiao, Jianpeng; Zhang, Qingying. Developing a dengue forecast model using machine learning: A case study in China. PLOS Neglected Tropical Diseases, v. 11, p. e0005973, 2017. DOI: 10.1371/journal.pntd.0005973.

[2] Johansson, Michael A.; Apfeldorf, Karyn M.; Dobson, Scott; Devita, Jason; Buczak, Anna L.; Baugher, Benjamin. An open challenge to advance probabilistic forecasting for dengue epidemics. Proceedings of the National Academy of Sciences, v. 116, p. 24268-24274, 2019. DOI: 10.1073/pnas.1909865116.

[3] Zhao, Naizhuo; Charland, Katia; Carabali, Mabel; Nsoesie, Elaine O.; Maheu-Giroux, Mathieu; Rees, Erin. Machine learning and dengue forecasting: Comparing random forests and artificial neural networks for predicting dengue burden at national and sub-national scales in Colombia. PLOS Neglected Tropical Diseases, v. 14, p. e0008056, 2020. DOI: 10.1371/journal.pntd.0008056.

[4] Johansson, Michael A.; Reich, Nicholas G.; Hota, Aditi; Brownstein, John S.; Santillana, Mauricio. Evaluating the performance of infectious disease forecasts: A comparison of climate-driven and seasonal dengue forecasts for Mexico. Scientific Reports, v. 6, 2016. DOI: 10.1038/srep33707.

[5] Chakraborty, Tanujit; Chattopadhyay, Swarup; Ghosh, Indrajit. Forecasting dengue epidemics using a hybrid methodology. Physica A: Statistical Mechanics and its Applications, v. 527, p. 121266, 2019. DOI: 10.1016/j.physa.2019.121266.

[6] Marques-Toledo, Cecilia de Almeida; Degener, Carolin Marlen; Vinhal, Livia; Coelho, Giovanini; Meira, Wagner; Codeço, Claudia Torres. Dengue prediction by the web: Tweets are a useful tool for estimating and forecasting Dengue at country and city level. PLOS Neglected Tropical Diseases, v. 11, p. e0005729, 2017. DOI: 10.1371/journal.pntd.0005729.

[7] Nguyen, Van-Hau; Tuyet-Hanh, Tran Thi; Mulhall, James; Minh, Hoang Van; Duong, Trung Q.; Chien, Nguyen Van. Deep learning models for forecasting dengue fever based on climate data in Vietnam. PLOS Neglected Tropical Diseases, v. 16, p. e0010509, 2022. DOI: 10.1371/journal.pntd.0010509.

[8] Xu, Jiucheng; Xu, Keqiang; Li, Zhichao; Meng, Fengxia; Tu, Taotian; Xu, Lei. Forecast of Dengue Cases in 20 Chinese Cities Based on the Deep Learning Method. International Journal of Environmental Research and Public Health, v. 17, p. 453, 2020. DOI: 10.3390/ijerph17020453.

[9] Yamana, Teresa K.; Kandula, Sasikiran; Shaman, Jeffrey. Superensemble forecasts of dengue outbreaks. Journal of The Royal Society Interface, v. 13, 2016. DOI: 10.1098/rsif.2016.0410.

[10] Mussumeci, Elisa; Codeço Coelho, Flávio. Large-scale multivariate forecasting models for Dengue - LSTM versus random forest regression. Spatial and Spatio-temporal Epidemiology, v. 35, p. 100372, 2020. DOI: 10.1016/j.sste.2020.100372.

[11] Salim, Nurul Azam Mohd; Wah, Yap Bee; Reeves, Caitlynn; Smith, Madison; Yaacob, Wan Fairos Wan; Mudin, Rose Nani. Prediction of dengue outbreak in Selangor Malaysia using machine learning techniques. Scientific Reports, v. 11, 2021. DOI: 10.1038/s41598-020-79193-2.

[12] Jain, Raghvendra; Sontisirikit, Sra; Iamsirithaworn, Sopon; Prendinger, Helmut. Prediction of dengue outbreaks based on disease surveillance, meteorological and

socio-economic data. BMC Infectious Diseases, v. 19, 2019. DOI: 10.1186/s12879-019-3874-x.

[13] Ramadona, Aditya Lia; Lazuardi, Lutfan; Hii, Yien Ling; Holmner, Åsa; Kusnanto, Hari; Rocklöv, Joacim. Prediction of Dengue Outbreaks Based on Disease Surveillance and Meteorological Data. PLOS ONE, v. 11, p. e0152688, 2016. DOI: 10.1371/journal.pone.0152688.

[14] Leung, Xing Yu; Islam, Rakibul M.; Adhami, Mohammadmehdi; Ilic, Dragan; McDonald, Lara; Palawaththa, Shanika. A systematic review of dengue outbreak prediction models: Current scenario and future directions. PLOS Neglected Tropical Diseases, v. 17, p. e0010631, 2023. DOI: 10.1371/journal.pntd.0010631.

[15] Anno, Sumiko; Hara, Takeshi; Kai, Hiroki; Lee, Ming-An; Chang, Yi; Oyoshi, Kei. Spatiotemporal dengue fever hotspots associated with climatic factors in Taiwan including outbreak predictions based on machine-learning. Geospatial Health, v. 14, 2019. DOI: 10.4081/gh.2019.771.

[16] Buczak, Anna L.; Baugher, Benjamin; Moniz, Linda J.; Bagley, Thomas; Babin, Steven M.; Guven, Erhan. Ensemble method for dengue prediction. PLOS ONE, v. 13, p. e0189988, 2018. DOI: 10.1371/journal.pone.0189988.

[17] Carvajal, Thaddeus M.; Viacrusis, Katherine M.; Hernandez, Lara Fides T.; Ho, Howell T.; Amalin, Divina M.; Watanabe, Kozo. Machine learning methods reveal the temporal pattern of dengue incidence using meteorological factors in metropolitan Manila, Philippines. BMC Infectious Diseases, v. 18, 2018. DOI: 10.1186/s12879-018-3066-0.

[18] Scavuzzo, Juan M.; Trucco, Francisco; Espinosa, Manuel; Tauro, Carolina B.; Abril, Marcelo; Scavuzzo, Carlos M.. Modeling Dengue vector population using remotely sensed data and machine learning. Acta Tropica, v. 185, p. 167-175, 2018. DOI: 10.1016/j.actatropica.2018.05.003.

[19] Hoyos, William; Aguilar, Jose; Toro, Mauricio. Dengue models based on machine learning techniques: A systematic literature review. Artificial Intelligence in Medicine, v. 119, p. 102157, 2021. DOI: 10.1016/j.artmed.2021.102157.

[20] Dey, Samrat Kumar; Rahman, Md. Mahbubur; Howlader, Arpita; Siddiqi, Umme Raihan; Uddin, Khandaker Mohammad Mohi; Borhan, Rownak. Prediction of dengue incidents using hospitalized patients, metrological and socio-economic data in Bangladesh: A machine learning approach. PLOS ONE, v. 17, p. e0270933, 2022. DOI: 10.1371/journal.pone.0270933.

[21] Souza, Caio; Maia, Pedro; Stolerman, Lucas M.; Rolla, Vitor; Velho, Luiz. Predicting dengue outbreaks in Brazil with manifold learning on climate data. Expert Systems with Applications, v. 192, p. 116324, 2022. DOI: 10.1016/j.eswa.2021.116324.

[22] Sebastianelli, Alessandro; Spiller, Dario; Carmo, Raquel; Wheeler, James; Nowakowski, Artur; Jacobson, Ludmilla Viana. A reproducible ensemble machine learning approach to forecast dengue outbreaks. Scientific Reports, v. 14, 2024. DOI: 10.1038/s41598-024-52796-9.

[23] Yavari Nejad, Felestin; Varathan, Kasturi Dewi. Identification of significant climatic risk factors and machine learning models in dengue outbreak prediction. BMC Medical Informatics and Decision Making, v. 21, 2021. DOI: 10.1186/s12911-021-01493-y.

[24] Codeço, Cláudia T; Cruz, Oswaldo G; Riback, Thais I; Degener, Carolin M; Gomes, Marcelo F; Villela, Daniel. InfoDengue: a nowcasting system for the surveillance of dengue fever transmission. 2016. DOI: 10.1101/046193.

[25] Codeco, C.; Coelho, F.; Cruz, O.; Oliveira, S.; Castro, T.; Bastos, L.. Infodengue: A nowcasting system for the surveillance of arboviruses in Brazil. Revue d'Épidémiologie et de Santé Publique, v. 66, p. S386, 2018. DOI: 10.1016/j.respe.2018.05.408.

[26] Shimabukuro, Yosio Edemir; dos Santos, João Roberto; Formaggio, Antonio Roberto; Duarte, Valdete; Theodor Rudorff, Bernardo Friedrich. The Brazilian Amazon Monitoring Program: PRODES and DETER Projects. Global Forest Monitoring from Earth Observation, p. 153-169, 2016. DOI: 10.1201/b13040-9.

[27] Gorelick, Noel; Hancher, Matt; Dixon, Mike; Ilyushchenko, Simon; Thau, David; Moore, Rebecca. Google Earth Engine: Planetary-scale geospatial analysis for everyone. Remote Sensing of Environment, v. 202, p. 18-27, 2017. DOI: 10.1016/j.rse.2017.06.031.

[28] Breiman, Leo. Random Forests. Machine Learning, v. 45, p. 5-32, 2001. DOI: 10.1023/A:1010933404324.

[29] Kaufman, Shachar; Rosset, Saharon; Perlich, Claudia; Stitelman, Ori. Leakage in data mining. ACM Transactions on Knowledge Discovery from Data, v. 6, p. 1-21, 2012. DOI: 10.1145/2382577.2382579.

[30] Elith, J.; Leathwick, J. R.; Hastie, T.. A working guide to boosted regression trees. Journal of Animal Ecology, v. 77, p. 802-813, 2008. DOI: 10.1111/j.1365-2656.2008.01390.x.

[31] Queiroz, Eny Regina da Silva; Medronho, Roberto de Andrade. Spatial analysis of the incidence of Dengue, Zika and Chikungunya and socioeconomic determinants in the city of Rio de Janeiro, Brazil. Epidemiology and Infection, v. 149, 2021. DOI: 10.1017/s0950268821001801.

[32] Bermudi, Patricia Marques Moralejo; Palasio, Raquel Gardini Sanches; Pirani, Monica; Santana, Lidia Maria Reis; Barbosa, Gerson Laurindo; Blangiardo, Marta. Dengue incidence, mortality, and case-fatality in Brazil: spatial patterns, socioeconomic contrasts, and serotype impact. Travel Medicine and Infectious Disease, v. 68, p. 102934, 2025. DOI: 10.1016/j.tmaid.2025.102934.

[33] Li, Zhichao; Dong, Jinwei. Big Geospatial Data and Data-Driven Methods for Urban Dengue Risk Forecasting: A Review. Remote Sensing, v. 14, p. 5052, 2022. DOI: 10.3390/rs14195052.

[34] Fuller, Douglas O.; Troyo, Adriana; Calderón-Arguedas, Olger; Beier, John C.. Dengue vector (Aedes aegypti) larval habitats in an urban environment of Costa Rica analysed with ASTER and QuickBird imagery. International Journal of Remote Sensing, v. 31, p. 3-11, 2010. DOI: 10.1080/01431160902865756.

[35] Singh, Shubham K.; Fan, Peilei; Chen, Jiquan. Ecoregion-specific dengue risk prediction in Peru using remote sensing, machine learning, and spatiotemporal modeling. Science of Remote Sensing, v. 14, p. 100490, 2026. DOI: 10.1016/j.srs.2026.100490.

[36] Brum-Bastos, Vanessa; Long, Jed; Church, Katharyn; Robson, Greg; de Paula, Rogério; Demšar, Urška. Multi-source data fusion of optical satellite imagery to characterize habitat selection from wildlife tracking data. Ecological Informatics, v. 60, p. 101149, 2020. DOI: 10.1016/j.ecoinf.2020.101149.

[37] Lima, Hélder; Tupinambás, Unaí; Guimarães, Frederico. Estimating epidemiological parameters and underreporting of Covid-19 cases in Brazil using a multi-wave mathematical model. 2023. DOI: 10.21203/rs.3.rs-3161529/v1.

[38] Cabrera, Maritza; Leake, Jason; Naranjo-Torres, José; Valero, Nereida; Cabrera, Julio C.; Rodríguez-Morales, Alfonso J.. Dengue Prediction in Latin America Using Machine Learning and the One Health Perspective: A Literature Review. Tropical Medicine and Infectious Disease, v. 7, p. 322, 2022. DOI: 10.3390/tropicalmed7100322.

[39] Thirugnanam, Archana; Hussain, Faritha Banu Jahir. Exploring Machine Learning Algorithms for the Prediction of Dengue: A Comprehensive Review. Revue d'Intelligence Artificielle, v. 37, p. 1281-1290, 2023. DOI: 10.18280/ria.370521.

[40] Iqbal, Naiyar; Islam, Mohammad. Machine learning for dengue outbreak prediction: A performance evaluation of different prominent classifiers. Informatica, v. 43, 2019. DOI: 10.31449/inf.v43i3.1548.